**ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH – TRƯỜNG ĐẠI HỌC BÁCH KHOA**
**KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH – BỘ MÔN KHOA HỌC MÁY TÍNH**

**BẢN ĐỀ XUẤT ĐỀ TÀI ĐỒ ÁN TỔNG HỢP**
**CHUYÊN NGÀNH: TRÍ TUỆ NHÂN TẠO**

# SEMSYNTH: Hệ thống tổng hợp chương trình tương tác người dùng dựa trên độ tăng thông tin ngữ nghĩa

*(Semantic Information Gain for Robust Human-in-the-Loop Program Synthesis)*

**Giảng viên hướng dẫn:** TS. Võ Thanh Hùng
**Nhóm sinh viên thực hiện:** (03 thành viên)

| STT | Họ và tên sinh viên | Mã số sinh viên | Địa chỉ Email |
|---|---|---|---|
| 1 | [Nguyễn Thành Đạt] (Nhóm trưởng) | [2410709] | [dat.nguyen19052006@hcmut.edu.vn] |
| 2 | [Đặng Bá Ty] | [2213893] | [ty.dangcodetogrow@hcmut.edu.vn] |
| 3 | [Nguyễn Tiến Vũ Bảo] | [2410281] | [bao.nguyenlqdvt16@hcmut.edu.vn] |

## 1. Ý tưởng sơ bộ & Bài toán cần giải quyết

Trong lĩnh vực Khoa học Máy tính và Trí tuệ Nhân tạo, bài toán **Tổng hợp chương trình** (Program Synthesis) đóng vai trò then chốt trong việc tự động sinh mã nguồn thực thi từ các đặc tả mức cao. Tuy nhiên, các hệ thống tương tác người dùng hiện đại (Human-in-the-Loop – HITL) đang đối mặt với sự đánh đổi lớn giữa hiệu quả giao tiếp và độ tin cậy của chương trình, tạo ra **Khoảng cách ma sát nhận thức** (Cognitive Friction Gap):

- **Phương pháp lập trình qua ví dụ (Programming-by-Example – PBE):** Mặc dù có tính tất định cao trên các ca kiểm thử cụ thể, phương pháp này đòi hỏi người dùng phải xây dựng các cặp ví dụ vào–ra (*Input-Output Examples*) phức tạp. Điều này áp đặt tải nhận thức rất lớn lên người dùng, buộc họ phải suy nghĩ như trình biên dịch thay vì chuyên gia nghiệp vụ.
- **Phương pháp dựa trên mô hình ngôn ngữ lớn (LLM-based Synthesis):** Sinh mã trực tiếp từ mô tả ngôn ngữ tự nhiên thông qua các mô hình ngôn ngữ lớn diễn ra nhanh chóng nhưng dễ tạo ra mã nguồn ảo giác hoặc sai lệch nghiêm trọng khi đặc tả có tính mơ hồ cao hoặc chứa nhiễu (*ambiguous or noisy requirements*).

Để giải quyết bài toán **Làm rõ đặc tả mơ hồ** (Specification Ambiguity), đề tài đề xuất phát triển hệ thống chủ động đặt câu hỏi làm rõ ở mức ngữ nghĩa (Semantic Clarification Questions) dưới dạng Đúng/Sai hoặc trắc nghiệm (ví dụ: *"Hàm có cần xử lý tên miền phụ nhiều cấp như mail.example.com hay không?"*). Tiếp cận này cho phép thu hẹp không gian chương trình ứng viên một cách tối ưu với ma sát nhận thức tối thiểu cho người sử dụng.

## 2. Hướng tiếp cận dự kiến (Framework SEMSYNTH)

Hệ thống **SEMSYNTH** được thiết kế với kiến trúc ba thành phần cốt lõi nhằm giải quyết triệt để các thách thức kỹ thuật của mô hình tương tác HITL:

### 2.1. Pipeline tính toán độ tăng thông tin ngữ nghĩa (Semantic Information Gain)

Thành phần này chịu trách nhiệm định lượng độ bất định và lựa chọn câu hỏi tối ưu nhất để truy vấn người dùng:

- **Không gian đặc trưng 47 chiều:** Xây dựng vector đặc trưng kết hợp để mô tả cặp chương trình giả thuyết và câu hỏi $(h, q)$, bao gồm: **18 đặc trưng cấu trúc** trích xuất từ cây cú pháp trừu tượng (AST) của mã nguồn (độ sâu cây AST, số lượng toán tử, câu lệnh điều kiện, độ phức tạp Cyclomatic,...); **18 đặc trưng ngữ nghĩa/hành vi** (đệ quy, đột biến tham số đầu vào, tác dụng phụ, hàm bậc cao, xử lý ngoại lệ,...); và **11 đặc trưng văn bản** của câu hỏi (độ dài truy vấn, độ đặc thù, phân loại câu hỏi biên/chiến lược/cấu trúc).
- **Mô hình ánh xạ ngữ nghĩa $M(h, q)$:** Sử dụng thuật toán học máy Gradient Boosted Trees (XGBoost) để phân lớp và dự đoán xác suất giả thuyết $h$ thỏa mãn câu hỏi ngữ nghĩa $q$ (tức $P(a = \text{"Yes"} \mid h, q)$) trong thời gian thực.
- **Lựa chọn câu hỏi theo Tiêu chuẩn Maximin (Maximin Criterion):** Dựa trên lý thuyết thông tin, độ tăng thông tin kỳ vọng (Information Gain – $IG$) được tính thông qua độ giảm entropy Shannon $H(\mathcal{H})$ của không gian giả thuyết $\mathcal{H}$:

$$IG(q) = H(\mathcal{H}) - \sum_{a \in \mathcal{A}} P(a \mid q)\, H(\mathcal{H} \mid q, a) \tag{1}$$

Để đảm bảo tính bền vững (robustness) trong kịch bản người dùng phản hồi bất lợi nhất, hệ thống áp dụng **Tiêu chuẩn Maximin** ($q^* = \arg\max_{q \in \mathcal{Q}} \min_{a \in \mathcal{A}} \Delta H(q, a)$), ưu tiên câu hỏi đảm bảo loại bỏ được lượng lớn nhất các giả thuyết sai ngay cả trong trường hợp xấu nhất.

### 2.2. Cơ chế cập nhật niềm tin kháng mâu thuẫn (Contradiction-Aware Belief Revision)

Trong các phiên tương tác thực tế, người dùng có thể vô tình cung cấp các phản hồi mâu thuẫn do hiểu nhầm ngữ cảnh. SEMSYNTH thiết kế cơ chế tự phục hồi thông qua:

- **Phát hiện phân kỳ (Divergence Detection):** Theo dõi lịch sử tương tác $\mathcal{D}_t = \{(q_i, a_i)\}_{i=1}^{t}$ để phát hiện mâu thuẫn trực tiếp giữa các câu hỏi tương đương, đồng thời định lượng sự trôi dạt niềm tin qua độ phân kỳ Kullback-Leibler (KL Divergence).
- **Tái trọng số nhất quán (Consistency Re-weighting):** Thay vì loại bỏ cứng (hard filtering) khiến không gian nghiệm bị rỗng khi gặp phản hồi sai, hệ thống cập nhật phân phối xác suất mềm (soft Bayesian belief update). Các giả thuyết được gán trọng số tin cậy tương ứng với mức độ nhất quán lịch sử, giúp bảo toàn các ứng viên tiềm năng mà không phải khởi động lại toàn bộ quá trình tổng hợp.

### 2.3. Quản lý không gian giả thuyết phân tầng (Tiered Hypothesis Management)

Khi không gian tìm kiếm chương trình mở rộng lên quy mô $10^3 - 10^5$ ứng viên, việc đánh giá toàn bộ các cặp $(h, q)$ sẽ gây tắc nghẽn thời gian thực. SEMSYNTH đề xuất cơ chế phân tầng:

- **Tầng 1 (Beam-style Pruning):** Cắt tỉa không gian và duy trì chùm các giả thuyết có điểm thích nghi (fitness score) cao nhất.
- **Tầng 2 (Clustering Proxies):** Gom cụm phân cấp các giả thuyết dựa trên sự tương đồng về cấu trúc mã nguồn và hành vi thực thi, từ đó trích xuất các phần tử đại diện cụm (cluster representatives) để tính toán $IG$, giảm thiểu đột biến chi phí tính toán tại mỗi vòng lặp tương tác.

## 3. Các nội dung liên quan đã tìm hiểu (Related Work)

Đề tài được xây dựng trên nền tảng nghiên cứu có hệ thống từ các công trình khoa học uy tín:

1. **Tổng hợp chương trình dựa trên ví dụ (PBE):** Khảo sát cấu trúc **Đại số Không gian Phiên bản (Version Space Algebra – VSA)** và các hàm chứng thực (*witness functions*) trong các hệ thống nền tảng như FlashFill và Microsoft PROSE để làm công cụ sinh không gian giả thuyết ban đầu.
2. **Hệ thống tương tác làm rõ (Clarification Models in HITL):** Nghiên cứu các mô hình làm rõ đặc tả như TiCoder, ClarifyGPT và hệ thống tổng hợp dựa trên suy diễn transductive SYNTRA (NeurIPS 2025) để đúc kết các quy chuẩn thiết kế câu hỏi làm rõ.
3. **Mô hình người dùng giả lập (Simulated User / LLM Oracles):** Nghiên cứu việc thiết lập các tác nhân LLM đóng vai trò người dùng giả lập (như Google Gemma, Gemini Flash, DeepSeek Coder) để tự động hóa quy trình kiểm thử độ bền vững của thuật toán trước các mức độ nhiễu khác nhau.

## 4. Kế hoạch triển khai dự kiến

Đồ án tổng hợp dự kiến hoàn thiện thông qua 4 giai đoạn cụ thể trong thời gian 01 tháng (4 tuần):

Bảng 1: Kế hoạch triển khai và các mốc hoàn thành đồ án dự kiến (trong 01 tháng)

| Giai đoạn | Thời gian | Nội dung công việc cốt lõi |
|---|---|---|
| Giai đoạn 1 | Tuần 1 | Xây dựng bộ khung tổng hợp chương trình; hoàn thiện bộ trích xuất 47 đặc trưng AST, hành vi và văn bản câu hỏi. |
| Giai đoạn 2 | Tuần 2 | Huấn luyện mô hình ánh xạ ngữ nghĩa $M(h, q)$ bằng XGBoost; cài đặt cơ chế cập nhật niềm tin kháng mâu thuẫn (Belief Revision). |
| Giai đoạn 3 | Tuần 3 | Tích hợp thuật toán chọn câu hỏi theo tiêu chuẩn Maximin; xây dựng giao diện tương tác người dùng thời gian thực (Web UI: ReactJS + FastAPI). |
| Giai đoạn 4 | Tuần 4 | Thực hiện thử nghiệm tương tác toàn diện trên các tác nhân giả lập (Cross-LLM Oracles); hoàn thiện báo cáo và bảo vệ đồ án. |

**Kết luận:** Đề tài sở hữu cơ sở lý thuyết vững chắc từ lý thuyết thông tin và học máy, định hướng kỹ thuật rõ ràng và giải quyết trực tiếp rào cản nhận thức trong bài toán tổng hợp chương trình. Nhóm sinh viên tin tưởng đề tài hoàn toàn khả thi và sẽ đạt kết quả tốt dưới sự định hướng chuyên môn của Thầy Võ Thanh Hùng.